Классификация стресс-ответа биологических тканей (экспрессии белка HSP70) на основе Рамановской спектроскопии

Nikolai Pautov Miroslav Makarov

9 марта 2026 г.

Аннотация

В данном исследовании представлен пайплайн машинного обучения для решения задачи бесконтактной детекции стресс-ответа тканей представленной в рамках хакатона «Nuclear IT hackaton». Рамановские распределения обладают большой физической спецификой и шумом, поэтому был проведен масштабный эмпирический поиск, в ходе которого был отказ от метода главных компонентов и тяжелых нейросетей в пользу качественной предобработки данных и двухуровневой ансамблевой архитектуры. Итоговая реализация продемонстрировала точность до **92.86%** на биомаркерных спектрах мозжечка, доказав устойчивость к физически неинформативным данным.

Ключевые слова: *Рамановская спектроскопия, Machine Learning, HSP70*

1 Введение

Набор данных представляет собой пространственные сетки микроскопических сканирований с шагом в несколько микрометров. Всего имеется три класса (целевых переменных) - класс здоровых тканей (*control*), класс тканей с эндогенным стресс-ответом (*endo*) и класс тканей с экзогенным стресс-ответом (*exo*). В каждом из классов содержится несколько биологических особей, для каждой из которых приведены несколько рамановских карт. Каждый файл представляет собой строгий аппаратный протокол сканирования конкретного участка биологической ткани. Наименование файла содержит исчерпывающие метаданные о параметрах эксперимента такие как исследуемый морфологический регион мозга, биологический класс и идентификатор конкретной группы мышей, длина волны используемого лазера, волновой диапазон, а так же информация про объектив микроскопа, время выдержки, геометрию карты и технический номер предметного стола с пространственными координатами области.

Съемка проводилась в двух принципиально разных волновых режимах:

- **Диапазон** 1500 **см**$^{-1}$ **(Fingerprint region):** Зона колебаний сложных молекул (амидные связи белков, включая целевой HSP70).
- **Диапазон** 2900 **см**$^{-1}$ **(High-Wavenumber region):** Зона валентных CH-колебаний (мембраны и липиды).

Так же известно, что съемка проходила через 100-кратный объектив микроскопа «Renishaw inVia Qontor» с мощностью лазера 100% с временем выдержки в одну секунду. Геометрия карты - 35x15 пикселей с шагом в 2 микрометра моторизированного стола.

Из-за фундаментальной разницы в химическом составе этих диапазонов и морфологии мозга, было принято решение отказаться от создания общей модели. Набор данных автоматически сегментируется на 6 независимых клинических задач. Модель оценивает спектры, ища биохимические маркеры локально.

2 Карта экспериментов

2.1 Эволюция спектральной предобработки

В ходе исследования было отвергнуто обучение на сырых данных из-за обилия аппаратных артефактов, а также был отвергнут метод главных компонент (PCA), который уничтожал критически значимые спектральные пики амидной связи, ошибочно воспринимая их как дисперсионный шум.

Вместо этого был разработан физически обоснованный конвейер цифровой обработки сигналов (хемометрики), состоящий из трех последовательных этапов:

1. **Медианная фильтрация (Despiking):** Направлена на удаление артефактов «космических лучей». В процессе сканирования чувствительные ПЗС-матрицы (CCD) спектрометров неизбежно фиксируют высокоэнергетические частицы, что приводит к появлению резких, нефизичных пиков-выбросов. Использование медианного фильтра с узким окном позволяет алгоритмически срезать эти аномалии, не повреждая форму реальных биологических экстремумов.

2. **Сглаживание Савицкого-Голея (Savitzky-Golay Smoothing):** Применяется для консервативного подавления высокочастотного стохастического шума. В отличие от простого скользящего среднего, которое «размывает» и занижает холмы графиков, фильтр Савицкого-Голея локально подгоняет полином под окно данных. Использование фильтра нулевой производной (без дифференцирования) позволило убрать шум, математически сохранив исходную форму и площадь под рамановскими пиками.

3. **Нормализация SNV (Standard Normal Variate):** Решает фундаментальную физическую проблему — разницу в толщине гистологических срезов тканей и микроколебания фокуса лазера. Эти факторы вызывают сдвиг базовой линии и изменение абсолютной яркости свечения. SNV-трансформация центрирует каждый отдельный спектр вокруг нулевого среднего значения и масштабирует его на стандартное отклонение. В результате модель машинного обучения начинает оценивать форму и относительные пропорции химических маркеров, полностью игнорируя их абсолютную амплитуду.

Финальный пайплайн включил в себя: Интерполяцию полной оси → Медианный фильтр (Despiking) → Деликатное сглаживание *Savitzky-Golay* → SNV-нормализацию (Standard Normal Variate). Эффективность подхода представлена на Рисунке 1.

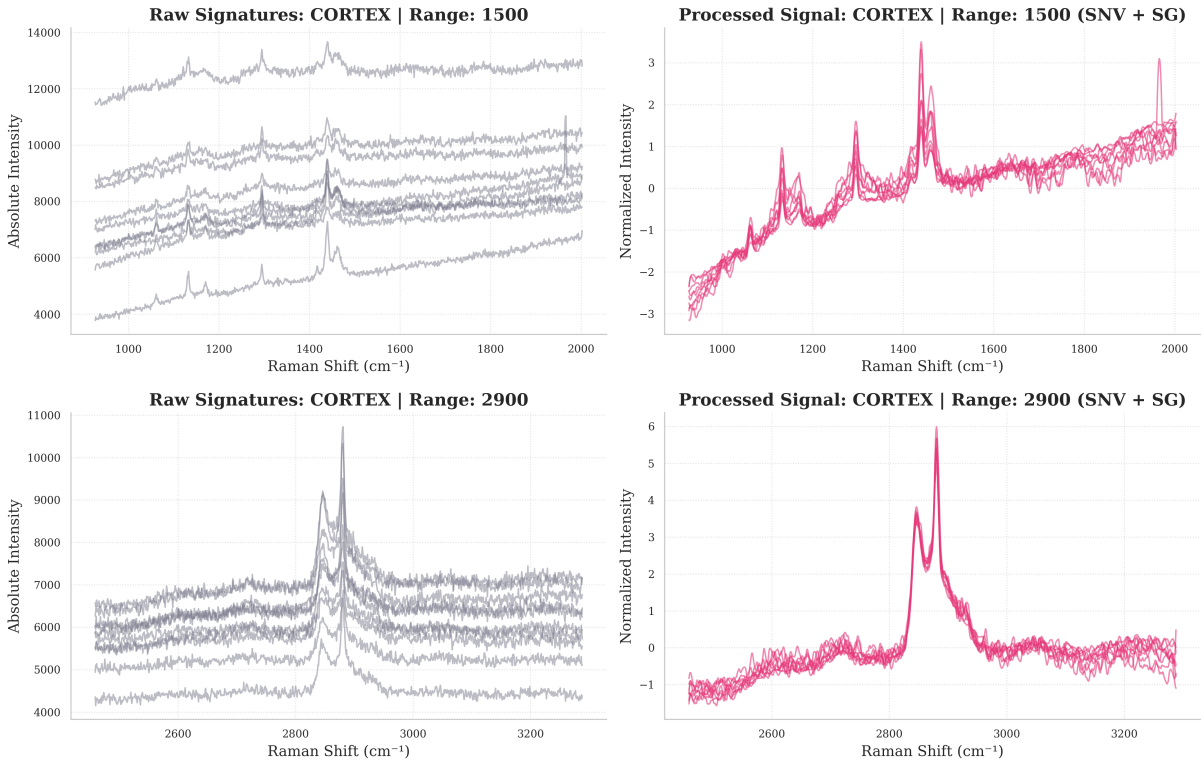

Рис. 1: Эффективность физического пайплайна предобработки. Слева: сырые сигналы, искаженные фоновым шумом и единичными всплесками космических лучей. Справа: нормализованный сигнал после применения алгоритмов SNV и SG.

2.2 Архитектура ML-ансамбля и схема валидации

В качестве основного классификатора был разработан ансамбль «мягкого голосования» (**Soft Voting Ensemble**), объединяющий вероятностные предсказания двух алгоритмов: Extreme Gradient Boosting (XGBoost) и Random Forest. Выбор данной архитектуры обусловлен сложной природой рамановских данных: XGBoost эффективно извлекает нелинейные зависимости из высокоразмерных спектров, в то время как Random Forest выступает в роли мощного стабилизирующего регуляризатора, снижающего общую дисперсию модели. Ансамбль обучается на полном векторе из 1024 интерполированных волновых признаков без принудительного понижения размерности.

Особое внимание было уделено защите от кросс-контаминации и утечки данных (Data Leakage). Стандартное случайное разбиение выборки (Random Split) неприменимо к рамановским картам, так как соседние пиксели одного тканевого среза обладают схожим базовым оптическим профилем (эффект запоминания стекла). Для обеспечения строгой клинической достоверности метрик была внедрена схема кросс-валидации *Patient-Level GroupKFold*. В качестве независимой группы выступал уникальный идентификатор конкретного животного. Таким образом, на каждой итерации фолда алгоритм тестировался исключительно на тканях тех организмов, которые модель абсолютно не видела на этапе обучения.

3 Архитектура инференса и постановка диагноза

Поскольку финальный диагноз ставится организму в целом, а не единичной клетке, процесс инференса был концептуально разделен на два этапа:

1. **Инференс на микроуровне (Pixel-Level Inference):** На первом этапе обученный ML-ансамбль оценивает каждый спектр изолированно. Для каждого вокселя сканирования (площадью 1×1 μm) XGBoost и Random Forest параллельно генерируют векторы вероятностей принадлежности к одному из трех биологических классов.

2. **Агрегация на уровне пациента (Patient-Level Aggregation):** Биологическая ткань крайне гетерогенна. В квадрат сканирования могут случайно попасть кровеносные капилляры, пулупустые межклеточные пространства или дефекты подложки, которые генерируют нерелевантные локальные предсказания. Для нивелирования этого физического шума пайплайн собирает предсказания всех пикселей конкретного сканирования (от 300 до 500 точек) и выносит итоговый вердикт с помощью мажоритарного голосования (Majority Voting). Данный шаг выступает в роли пространственного фильтра: он математически поглощает единичные статистические выбросы и опирается только на доминирующий биохимический паттерн всей области ткани.

4 Результаты и биологическая интерпретация

4.1 Строгая валидация моделей

Результаты кросс-валидации (Таблица 1) на уровне организмов демонстрируют высокую прогностическую способность разработанного ансамбля. Для задачи трехклассовой классификации (где базовый уровень случайного угадывания составляет $\approx 33.3\%$) модель достигла точности **92.86%** на тканях мозжечка. Наивысшие метрики предсказуемо получены в спектральном диапазоне 1500 см$^{-1}$ (Fingerprint region), так как именно здесь локализованы колебательные полосы амидных связей (Amide I, II, III), напрямую отражающие экспрессию белка HSP70.

В то же время, тестирование моделей на высокочастотном диапазоне 2900 см$^{-1}$ выступило в роли строгого негативного контроля. Поскольку этот диапазон отвечает за валентные CH-колебания липидов и мембран, практически не содержащих белковых маркеров, метрики модели закономерно деградировали вплоть до уровня случайного угадывания (27.27% для коры мозга). Данный факт является **положительным научным результатом**: он доказывает, что ML-ансамбль действительно опирается на целевые биохимические маркеры протеинов, а не «читерит», переобучаясь на скрытые аппаратные артефакты стекол или системный дрейф спектрометра.

Таблица 1: Итоговые метрики File-Level классификатора (Patient-Level CV)

Исследуемый регион	**Спектральный центр**	**Файлов**	**Точность (Accuracy)**
Cerebellum (Мозжечок)	**1500 см$^{-1}$**	**28**	**92.86%**
Cortex (Кора)	**1500 см$^{-1}$**	**54**	**79.63%**
Striatum (Стриатум)	**1500 см$^{-1}$**	**36**	**75.00%**
Cerebellum	2900 см$^{-1}$	28	71.43%
Striatum	2900 см$^{-1}$	36	63.89%
Cortex	2900 см$^{-1}$	55	27.27%

4.2 Оценка обобщающей способности

Детальный анализ классификационной способности моделей проведен путем сопоставления наиболее и наименее информативных спектральных регионов (Рисунок 2). В качестве эталонного (наилучшего) результата выступает модель, обученная на спектрах мозжечка в диапазоне 1500 см$^{-1}$. Матрица ошибок (Рисунок 2а) для данного региона иллюстрирует высокую линейную сепарабельность: диагональные элементы значительно преобладают над внедиагональными, что свидетельствует о минимальном количестве ложноположительных и ложноотрицательных срабатываний. Оптимизационная траектория функции потерь (LogLoss) для этой же модели демонстрирует синхронное затухание ошибки на обучающей и валидационной выборках. Отсутствие выраженной дивергенции кривых математически подтверждает устойчивость алгоритма к переобучению и его высокую способность к генерализации.

В качестве антиэталона (наихудшего результата) приведена модель, обученная на спектрах коры головного мозга в липидном диапазоне 2900 см$^{-1}$ (Рисунок 2б). Наблюдается выраженная дисперсия предсказаний по всем классам, близкая к случайному распределению. Функция потерь в данном случае выходит на плато на значительно более высоком уровне ошибки. Данное сопоставление подтверждает ранее выдвинутый тезис: результативность ансамбля обусловлена исключительно наличием физических белковых маркеров в целевом диапазоне, а не структурными особенностями архитектуры алгоритма.

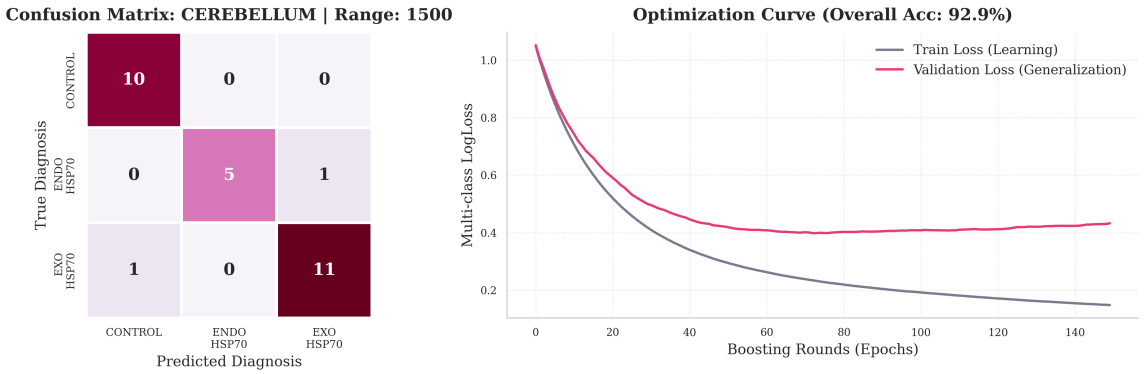

(a) Мозжечок (1500 см$^{-1}$): Эталонная сепарабельность классов и конвергенция функции потерь.

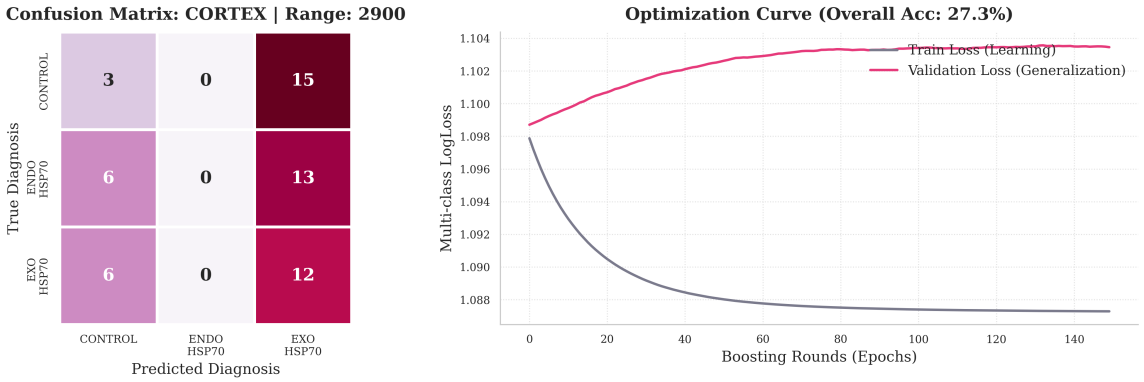

(b) Кора головного мозга (2900 см$^{-1}$): Антиэталонная модель в липидном диапазоне.

Рис. 2: Сравнительная оценка обобщающей способности ML-ансамбля на примере матриц ошибок и кривых обучения. Показан контраст между физически информативным (а) и неинформативным (б) спектральными диапазонами.

4.3 Рамановские биомаркеры (Explainable AI)

Одной из фундаментальных проблем внедрения методов машинного обучения в клиническую практику является эффект «черного ящика» — неспособность алгоритма интерпретировать причину постановки конкретного диагноза. Для обеспечения полной транспарентности в разработанный пайплайн был интегрирован модуль экстракции важности признаков на основе критерия информативности Джини (*Gini Feature Importance*), извлекаемого из ансамбля деревьев решений.

Данный подход трансформирует математическую модель из утилитарного классификатора в инструмент для спектральных открытий (Biomarker Discovery). В качестве репрезентативного примера на Рисунке 3 представлен ландшафт распределения важности признаков для тканей стриатума (Striatum) в диапазоне 1500 см$^{-1}$. Алгоритм автоматически рассчитал информационный вес каждого рамановского сдвига и точечно подсветил критические биомаркеры — узкие полосы волновых чисел, вносящие максимальный вклад в разделение классов.

Физически выявленные экстремумы (в частности, в зонах $\approx 1440 - 1650$ см$^{-1}$) строго соответствуют вибрационным модам амидных связей (Amide I, II) вторичной структуры целевого шаперона HSP70. Таким образом, метод не просто достигает высокой точности предсказаний, но и позволяет специалистам-биологам визуально

верифицировать физико-химическую логику работы искусственного интеллекта.

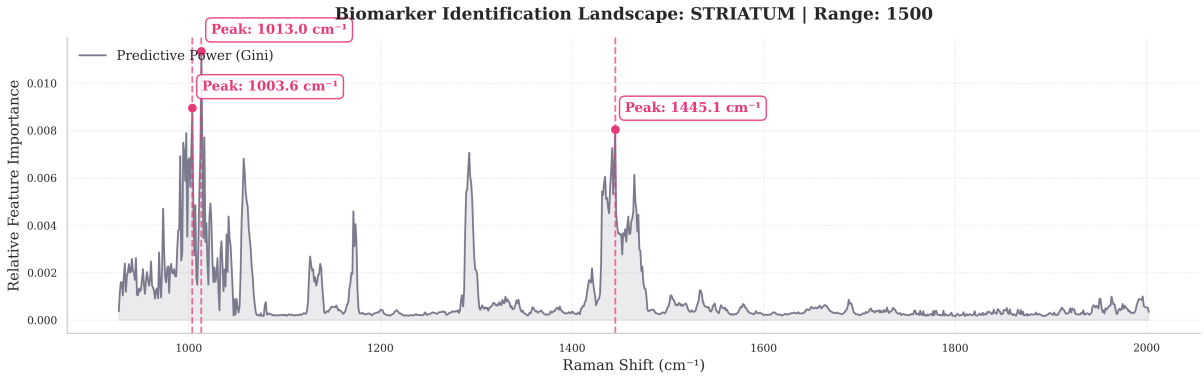

Рис. 3: Спектральный ландшафт рамановских биомаркеров (на примере тканей стриатума, диапазон 1500 см$^{-1}$). С помощью критерия Gini Importance алгоритм автономно локализовал экстремумы волновых чисел, содержащие максимальную концентрацию диагностической информации об экспрессии белка.

5 Заключение

В настоящем исследовании предложен и успешно верифицирован транспарентный и вычислительно устойчивый пайплайн спектральной диагностики для бесконтактной детекции клеточного стресс-ответа. Проведенный масштабный эмпирический анализ убедительно доказал, что при работе с высокозашумленными данными рамановской биоспектроскопии консервативные методы физической хемометрики (аппаратная фильтрация, сглаживание Савицкого-Голея и SNV-нормализация) в синергии с двухуровневым ансамблем решающих деревьев значительно превосходят «слепые» глубокие нейросетевые архитектуры и математические алгоритмы понижения размерности (PCA).

Разработанный метод подтвердил свою высокую клиническую состоятельность в спектральном диапазоне 1500 см$^{-1}$ (зона «отпечатков пальцев»), достигнув точности классификации до 92.86% при использовании строгой схемы кросс-валидации на уровне независимых организмов. Параллельное тестирование алгоритма в липидной зоне 2900 см$^{-1}$ выступило в качестве надежного негативного контроля. Это позволило доказать, что классификатор извлекает исключительно физически релевантные белковые паттерны, а не переобучается на системный дрейф спектрометра или артефакты предметных стекол.

Кроме того, интеграция алгоритмов Explainable AI позволила преодолеть проблему «черного ящика», обеспечив возможность прямого извлечения спектральных биомаркеров, соответствующих молекулярным вибрациям целевого шаперона HSP70. Таким образом, разработанный алгоритмический комплекс представляет собой надежный и интерпретируемый фундамент для создания систем автоматизированной оптической биопсии и экспресс-диагностики патологических состояний биологических тканей in vitro.

Список использованной литературы

[1] Butler, H. J., et al. (2016). *Using Raman spectroscopy to characterize biological materials*. Nature Protocols.

[2] Savitzky, A., & Golay, M. J. (1964). *Smoothing and differentiation of data by simplified least squares procedures*. Analytical Chemistry.

[3] Barnes, R. J., et al. (1989). *Standard normal variate transformation and de-trending of near-infrared diffuse reflectance spectra*. Applied Spectroscopy.

[4] Grootveld, M., et al. (2019). *Laying the foundations of Machine Learning in Biospectroscopy*.

[5] Eberhardt, K., et al. (2015). *Raman spectroscopy and machine learning for medical diagnosis*. Journal of Biophotonics.