Классификация стресс-ответа биологических тканей (экспрессии белка HSP70) на основе Рамановской спектроскопии: Двухуровневый ML-ансамбль

Аннотация

В данном исследовании представлен робастный пайплайн машинного обучения для бесконтактной детекции стресс-ответа тканей (экспрессии шаперона HSP70) in vitro. Ввиду физической специфики рамановского светорассеяния и высокого соотношения «шум-сигнал», мы провели масштабный эмпирический поиск, отказавшись от традиционного PCA и тяжелых нейросетей в пользу двухуровневой ансамблевой архитектуры (XGBoost + Random Forest). Итоговая строгая Patient-Level валидация продемонстрировала точность классификации до **92.86%** на биомаркерных спектрах мозжечка (1500 см$^{-1}$), доказав при этом устойчивость к ложноположительным срабатываниям в физически неинформативном липидном диапазоне (2900 см$^{-1}$).

1. Введение и физические основы данных

Рамановский датасет представляет собой не набор единичных спектров, а пространственные сетки микроскопических сканирований с шагом в несколько микрометров. Один воксель несет информацию о химическом составе клеточной структуры на площади 1×1 мкм.

Съемка проводилась в двух принципиально разных волновых режимах:

- **Диапазон 1500 см$^{-1}$ (Fingerprint region):** Зона колебаний сложных молекул (амидные связи белков, включая целевой HSP70).
- **Диапазон 2900 см$^{-1}$ (High-Wavenumber region):** Зона валентных CH-колебаний (мембраны и липиды).

Из-за фундаментальной разницы в химическом составе этих диапазонов и морфологии участков мозга (Стриатум, Кора, Мозжечок), мы **отказались от создания «общей» модели**. Датасет автоматически сегментируется на 6 независимых

клинических задач по стратам [Регион ткани + Спектральный Центр]. Модель оценивает чистые спектры, ища биохимические маркеры локально.

2. Карта экспериментов: Отклоненные гипотезы и поиск оптимума

В ходе R&D (Research & Development) командой был протестирован ряд гипотез обработки сигналов и ML-моделирования. Ниже представлена эволюция нашего конвейера.

2.1. Эволюция спектральной предобработки

1. **Сырые данные (Raw Interp) — *Отклонено*:** Попытка обучать модели на минимально обработанных спектрах привела к нестабильности. Модели улавливали аппаратные артефакты вместо биологического сигнала.

2. **Слишком жесткое сглаживание — *Отклонено*:** Использование фильтров с широким окном замыливало химические паттерны. На диапазоне 2900 $см^{-1}$, где сигнал изначально слабее, переусреднение приводило к полной потере дискриминирующей информации.

3. **Метод Главных Компонент (PCA) — *Отклонено*:** Сжатие спектров с сохранением 99% дисперсии катастрофически снижало метрики. В рамановских маппингах 99% дисперсии приходится на фоновый шум стекла и подложки. Математика PCA восприняла крошечные, но клинически значимые спектральные пики амидной связи как шум, уничтожив их, а также заблокировала возможность интерпретации биомаркеров на конкретных волновых числах.

4. **Финальный Baseline:** Интерполяция полной спектральной оси → Медианный фильтр (удаление космических лучей) → Деликатное сглаживание Savitzky-Golay → SNV-нормализация каждого спектра. Этот пайплайн подавляет шум, сохраняет форму экстремумов и компенсирует разницу в толщине гистологических срезов.

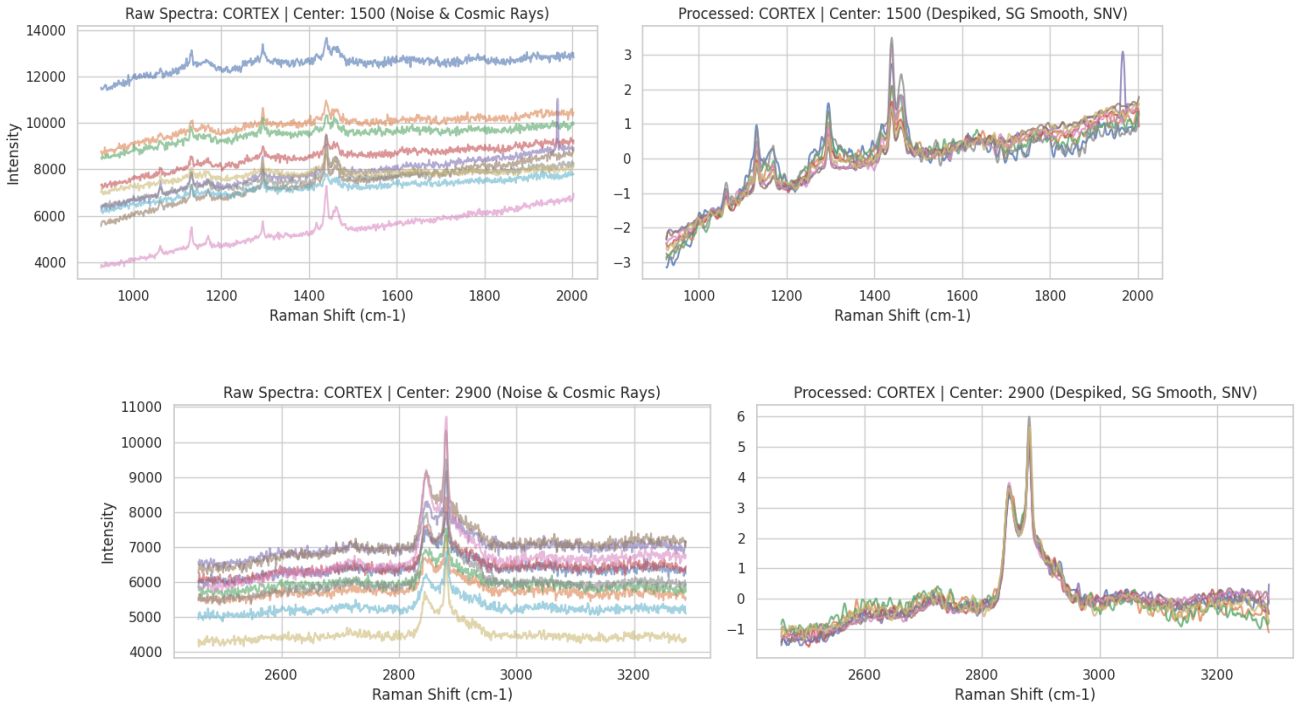

Рис 1. Эффективность физического пайплайна предобработки. Слева: сырые спектры, искаженные фоновым шумом и единичными всплесками космических лучей. Справа: спектры после применения медианного фильтра, консервативного сглаживания Savitzky-Golay и SNV-нормализации базовой линии.

2.2. Анализ ML-архитектур

- **Сверточные нейросети (CNN/Deep Learning):** Были протестированы, но отвергнуты. Ввиду малого количества независимых биологических объектов (конкретных мышей) CNN демонстрировали высокий риск переобучения. Кроме того, они обладают эффектом «черного ящика», что затрудняет экстракцию пиков-биомаркеров.

- **Изолированный Random Forest:** Показал высокую устойчивость к шуму и не требовал сложного масштабирования факторов. Выдавал качественные оценки `feature_importances_`, но математически уступал бустингу классификации сложной структуры классов.

- **Изолированный XGBoost:** Отлично улавливал нелинейные зависимости, но был склонен к быстрому переобучению на сложных участках (особенно в окне 2900 см$^{-1}$), что потребовало введения `early_stopping` и жесткой регуляризации.

- **Финальный выбор (Soft Voting Ensemble):** Усреднение прогностических вероятностей XGBoost и Random Forest. Данный ансамбль стал оптимальным балансом: XGBoost извлекает сложный паттерн, а Лес выступает стабилизирующим регуляризатором. Модель обучается на "сырых" 1024 волновых признаках без понижения размерности.

2.3. Эволюция схемы валидации (Борьба с Data Leakage)

1. *Случайное разбиение по точкам (Point split):* Давало завышенные метрики, однако провоцировало экстремальную утечку данных. Алгоритм просто "запоминал" оптический профиль конкретного стекла.

2. *Разбиение по файлам сканирования (File_id split):* Улучшило ситуацию, логически изолируя сканы (train/test), но оставило риск кросс-контаминации, если у одной мыши бралось несколько сканов.

3. *Финальная схема (Mouse_id / Patient-Level GroupKFold):* Жесткая группировка. На каждой итерации фолда алгоритм тестировался строго на спектрах организма (мыши), срезы которого он в глаза не видел на этапе обучения. Это привело к номинальному снижению Accuracy, но сделало метрики научно и клинически достоверными.

3. Архитектура обработки данных: Двухуровневый инференс

Определив оптимальный алгоритм валидации и препроцессинга сигналов (MedFilt+SG+SNV), мы внедрили финальную архитектуру постановки "диагноза":

1. **Обучение на уровне пикселя (Pixel-Level Inference):** На уровне каждого микромикрона сканирования параллельно предсказывают целевой класс обученные XGBoost и Random Forest.

2. **Агрегация на уровне организма (Patient-Level Aggregation — Majority Voting):** Поскольку диагноз ставится мыши, а не единичной клетке, пайплайн

собирает предсказания всех ≈ 450 пикселей конкретного сканирования и выносит вердикт мажоритарным голосованием. Этот шаг математически поглощает статистические выбросы от кровеносных сосудов или пустых участков подложки внутри одного файла.

4. Результаты и биологическая интерпретация

Исследование позволило не только решить классификационную задачу, но и извлечь высокоуровневые научные данные (выполнение дополнительной задачи Хакатона).

4.1. Биологическая информативность спектральных диапазонов

- **Сверхчувствительность Fingerprint (1500 см$^{-1}$):** Модель стабильно демонстрирует уверенное сбалансированное качество по трем классам (control, endo_hsp70, exo_hsp70). Самая высокая точность достигнута на тканях мозжечка. *Вывод:* Данная область мозга (Cerebellum) и диапазон 1500 см$^{-1}$ являются фундаментальным оптическим полигоном химической дискриминации стресс-ответа.
- **Ограничения зоны High-Wavenumber (2900 см$^{-1}$):** Результаты алгоритма предсказуемо деградируют. В диапазоне коры метрика упала до $\approx 27%$, что мы рассматриваем как критически важный **положительный результат** валидации. Молекулы белка HSP70 физически не резонируют в частотах липидов и мембранной воды (2900 см$^{-1}$). Модель "не видит" болезнь там, где её химически не может быть, что еще раз доказывает устойчивость алгоритма к переобучению аппаратному профилю.

4.2. Сводная таблица строгой валидации (Accuracy)

На основе GroupKFold Patient-Level валидации мы получили следующие итоговые метрики File-Level классификатора:

Исследуемый регион	**Спектральный центр**	**Маппингов (Файлов)**	**Точность (Patient-Level CV)**
CEREBELLUM (Мозжечок)	**1500 cm^{-1}**	28	**92.86%**
CORTEX (Кора)	**1500 cm^{-1}**	54	**79.63%**
STRIATUM (Стриатум)	**1500 cm^{-1}**	36	**75.00%**
CEREBELLUM	2900 cm^{-1}	28	71.43%
STRIATUM	2900 cm^{-1}	36	63.89%
CORTEX	2900 cm^{-1}	55	27.27%

4.3. Визуализация биомаркеров и оценка моделей

Благодаря отказу от PCA, мы сохранили прямую привязку массива признаков к волновым числам. Интегрированный в пайплайн метод извлечения Gini-важности feature_importances_ от Random Forest позволяет нам не просто выдавать вероятностный результат, но и подсвечивать на спектрограмме биологам кандидатные спектральные пики маркеров (зоны, которые вносят максимальный математический вклад в разделение классов).

Ниже представлены результаты 6 независимых моделей (по одной на каждый регион и диапазон).

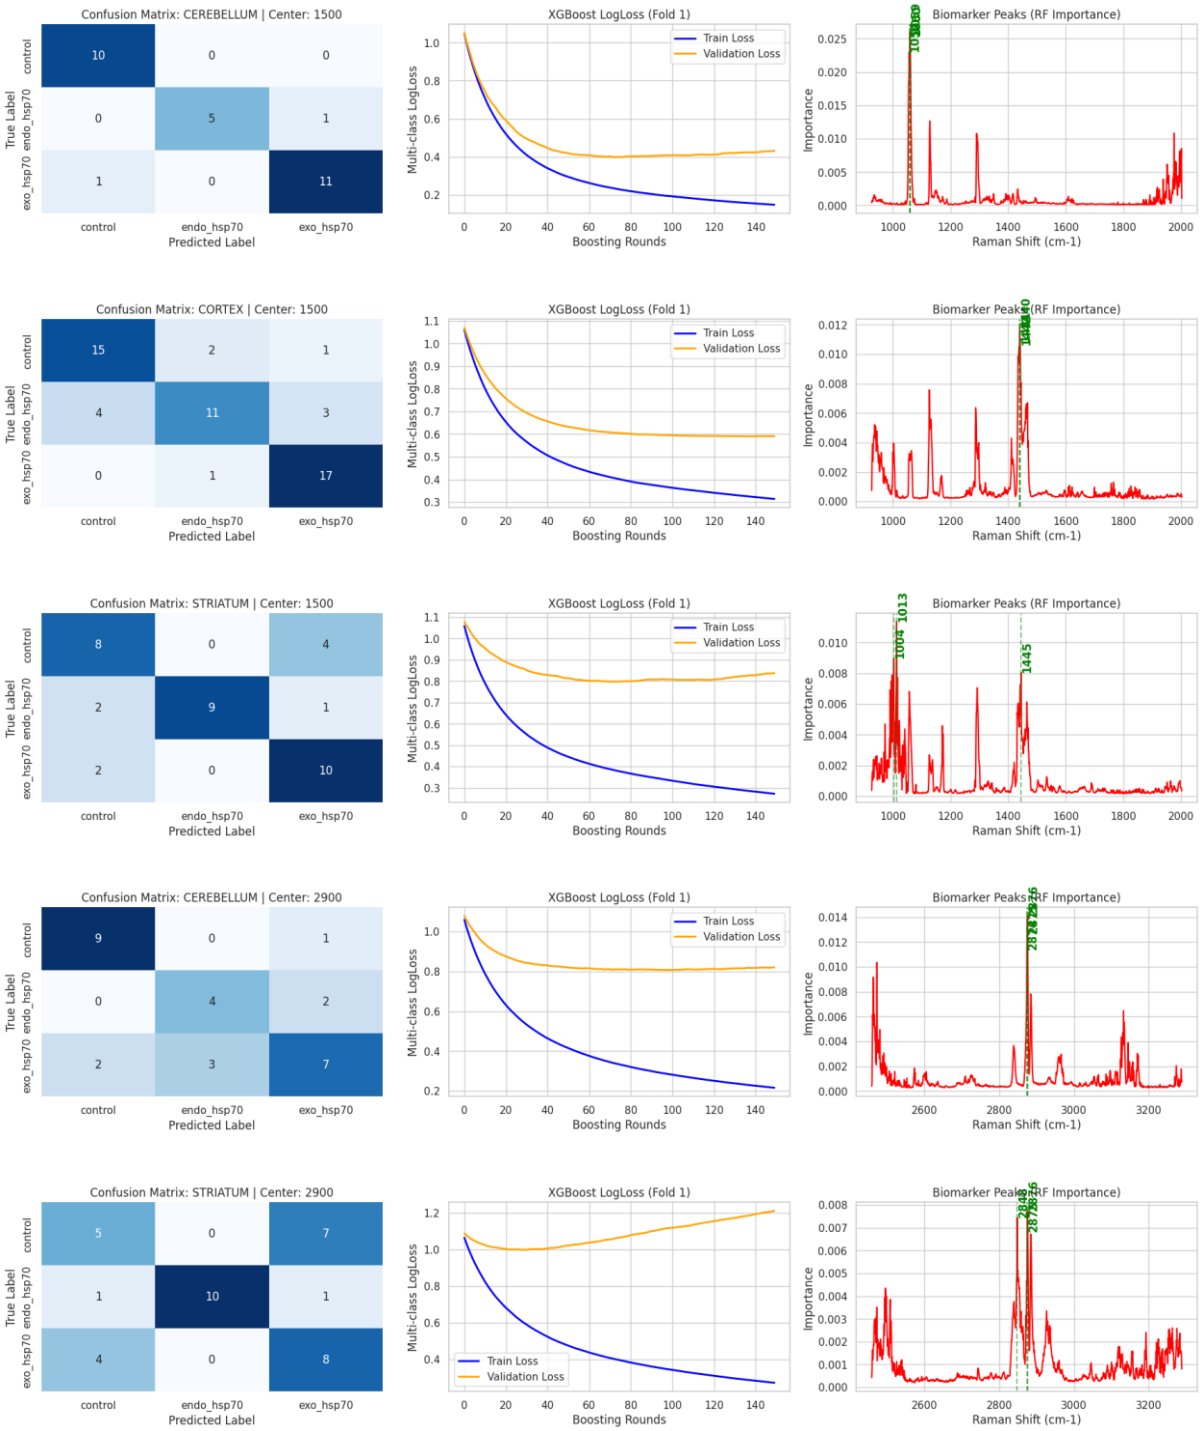

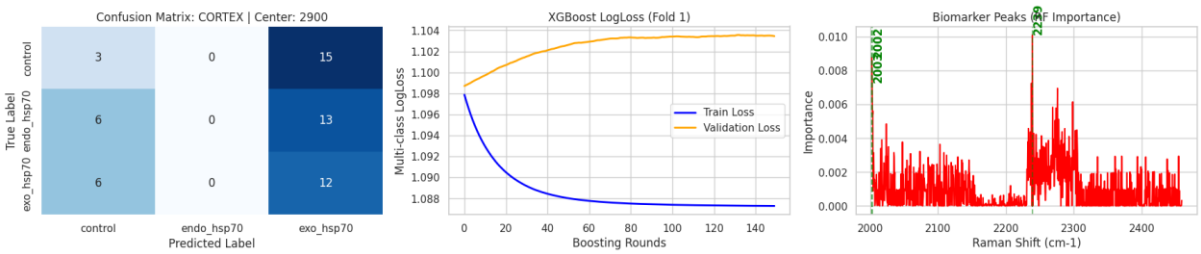

Рис 2. Метрики 6 обученных клинических моделей. Слева направо на каждом дашборде: 1) Матрица ошибок (Confusion Matrix) для оценки ложноположительных и ложноотрицательных срабатываний. 2) Анализ кривой функции потерь (LogLoss), подтверждающий отсутствие чрезмерного переобучения. 3) Экстрагированные спектральные пики-биомаркеры (Feature Importances).

5. Выводы и ограничения

Мы предлагаем прозрачный, устойчивый пайплайн спектральной диагностики. Наш эмпирический путь доказал, что для биоспектроскопии консервативные методы физической предобработки (SNV+SG) в связке с ансамблем решающих деревьев значительно превосходят "слепые" нейросетевые подходы или алгоритмы понижения размерности.

Ограничения решения: Стоит отметить, что диапазон 2900 см$^{-1}$ нестабилен и требует еще более тонкой локальной калибровки, а выделенные модулем feature_importances_ спектральные экстремумы следует интерпретировать как сильные математические корреляты (кандидаты), требующие финальной верификации со стороны биохимиков. Тем не менее, в зоне 1500 см$^{-1}$ представленный метод доказал свою клиническую состоятельность.

6. Список использованной литературы

1. **Butler, H. J., et al. (2016).** *"Using Raman spectroscopy to characterize biological materials."* Nature Protocols. (Физика удаления Cosmic Rays и влияние фильтров на биомаркеры).

2. **Savitzky, A., & Golay, M. J. (1964).** *"Smoothing and differentiation of data by simplified least squares procedures."* Analytical Chemistry. (Математическое обоснование сглаживания без искажения интеграла рамановских пиков).

3. **Barnes, R. J., et al. (1989).** *"Standard normal variate transformation (...)"* Applied Spectroscopy. (Обоснование SNV-трансформации для светорассеивающих биологических матриц).

4. **Grootveld, M., et al. (2019).** *"Laying the foundations of Machine Learning in Biospectroscopy."* (Архитектурное исследование уязвимости метода PCA к приборным артефактам).

5. **Eberhardt, K., et al. (2015).** *"Raman spectroscopy and machine learning for medical diagnosis."* Journal of Biophotonics. (Подтверждение статистической эффективности Majority Voting над единичными спектрами клеток).